

PDFs em Pipelines de RAG – Desafios, Armadilhas e Soluções

Se você já tentou construir um pipeline de RAG (Retrieval-Augmented Generation) com documentos PDF, provavelmente já se deparou com uma verdade desconfortável: o PDF é um dos formatos mais difíceis de processar para aplicações de IA. Criado originalmente para preservar a aparência visual de documentos (e não para facilitar a extração de conteúdo), o PDF esconde dentro de si uma série de armadilhas que podem comprometer a qualidade das respostas do seu sistema de IA Generativa com RAG e LLM.

Neste artigo, vamos explorar os principais desafios técnicos de trabalhar com PDFs em pipelines de RAG, entender por que cada um deles ocorre e apresentar as melhores soluções disponíveis atualmente para superá-los.

1. O Problema Fundamental: O PDF Não Foi Feito Para IA

O formato PDF (Portable Document Format) foi concebido pela Adobe nos anos 1990 com um único objetivo: garantir que um documento impresso ou visualizado em qualquer dispositivo ficasse exatamente igual ao original. Para isso, o PDF armazena informações como posições absolutas de caracteres na página, coordenadas de objetos gráficos e camadas de renderização, sem qualquer preocupação com a ordem semântica do conteúdo.

Isso cria um paradoxo fundamental para sistemas de RAG: enquanto um ser humano lê um PDF e entende intuitivamente que uma tabela no topo da página precede um parágrafo explicativo logo abaixo, um parser de texto simples pode ler o documento na ordem em que os caracteres foram armazenados, o que pode ser completamente diferente da ordem visual.

A contradição básica está na filosofia de design do PDF, que prioriza a preservação visual para consumo humano sobre a acessibilidade semântica para máquinas.

O resultado direto disso é que erros de parsing se propagam em cascata por todo o pipeline: um texto extraído de forma incorreta gera embeddings de baixa qualidade, que por sua vez levam a recuperações irrelevantes e, finalmente, a respostas incorretas ou alucinações do modelo de linguagem.

2. Extração de Texto: Quando o Simples se Torna Complexo

O primeiro desafio (e o mais fundamental) é a extração de texto puro. Existem basicamente dois tipos de PDF e cada um apresenta dificuldades distintas:

2.1 PDFs Nativos Digitais

PDFs criados diretamente por softwares como Word, LaTeX ou ferramentas de design contêm o texto armazenado como strings de caracteres. Em teoria, extrair esse texto deveria ser simples. Na prática, porém, surgem complicações como:

- Codificação incorreta de caracteres especiais (acentos, símbolos matemáticos)
- Ausência de separadores de palavras entre colunas adjacentes
- Hifenização no final de linhas que não representa quebras reais de palavras
- Metadados ausentes ou inconsistentes que dificultam a categorização

2.2 PDFs Escaneados e Baseados em Imagem

PDFs gerados a partir de digitalizações de documentos físicos armazenam o conteúdo como imagens. Aqui, o texto simplesmente não existe em forma de string, ele precisa ser reconhecido por OCR (Optical Character Recognition).

O desafio do OCR vai muito além de simplesmente “ler” caracteres. Erros clássicos incluem confusão entre caracteres visualmente similares (“1”, “l” e “I”; “0” e “O”), dificuldade com fontes não padronizadas, perda de estrutura em documentos com baixa qualidade de digitalização e falhas em documentos com ruído, manchas ou inclinação.

Pesquisas de 2025 (referências ao final do post) mostram que mesmo as soluções de OCR mais avançadas podem falhar na construção de bases de conhecimento de alta qualidade para sistemas de RAG que lidam com documentos reais e variados.

3. Tabelas: O Pesadelo Estrutural

Se a extração de texto já é desafiadora, tabelas representam um nível completamente diferente de complexidade. Uma tabela em um PDF é, na essência, um conjunto de caracteres posicionados em coordenadas específicas na página, sem qualquer tag semântica indicando que certos valores pertencem a determinadas linhas e colunas.

Parsers simples como PyPDF tendem a extrair tabelas lendo os caracteres na ordem em que estão armazenados no arquivo, resultando em conteúdo completamente embaralhado. Estudos mostram que quando os cabeçalhos de uma tabela aparecem apenas no chunk inicial, a parte inferior da tabela em chunks subsequentes torna-se essencialmente sem sentido para o LLM.

Os problemas específicos com tabelas incluem:

- Tabelas que se estendem por múltiplas páginas têm seus cabeçalhos perdidos nas páginas seguintes
- Células mescladas criam ambiguidade sobre a qual linha ou coluna um valor pertence
- Tabelas dentro de tabelas (aninhadas) são frequentemente descaracterizadas
- Tabelas com bordas invisíveis podem não ser detectadas como tabelas
- Valores numéricos com formatação especial (“1.234,56”) podem ser lidos incorretamente

Soluções como Docling utilizam modelos especializados de detecção de layout (DocLayNet) e reconhecimento de estrutura de tabelas (TableFormer) para preservar as relações entre linhas e colunas, mantendo o contexto semântico durante a extração.

4. Layouts Complexos: Multi-Colunas, Gráficos e Ordem de Leitura

Documentos acadêmicos, relatórios financeiros e materiais técnicos frequentemente utilizam layouts de múltiplas colunas, gráficos explicativos integrados ao texto, notas de rodapé que interrompem o fluxo do conteúdo e elementos flutuantes como caixas laterais e figuras com legendas.

4.1 O Problema da Ordem de Leitura

Em um documento de duas colunas, a ordem correta de leitura é: toda a coluna esquerda, depois toda a coluna direita. No entanto, um parser que lê por posição horizontal pode intercalar os textos das duas colunas, produzindo um resultado completamente ininteligível. Para um LLM que receberá esse texto como contexto, isso é catastrófico.

4.2 Figuras e Gráficos

Sistemas tradicionais de RAG foram projetados para dados em texto. Isso significa que figuras, gráficos e infográficos (que frequentemente contêm as informações mais relevantes de um documento técnico) são simplesmente ignorados ou, na melhor das hipóteses, substituídos por um marcador de posição sem conteúdo.

Uma pesquisa publicada no ViDoRe benchmark mostrou que abordagens baseadas em imagem de páginas de documentos (em vez de parsing textual) alcançam 81,3% de nDCG@5 em recuperação de documentos visuais, comparado a 67,0% para métodos tradicionais de parsing. Referências ao final do post.

5. Estratégias de Chunking: Dividir Sem Perder o Contexto

Mesmo quando o texto é extraído corretamente, a forma como ele é dividido em chunks para armazenamento no banco de vetores pode destruir o contexto necessário para respostas precisas. Esta é uma das decisões técnicas que mais impacta diretamente a performance do sistema de RAG.

5.1 Chunking por Token: A Abordagem Ingênua

A estratégia mais simples (dividir o documento em blocos de N tokens com sobreposição) é frequentemente a pior escolha para PDFs complexos. Ela pode dividir uma tabela no meio, separar uma pergunta da sua resposta ou cortar um argumento técnico no ponto exato em que ele se tornaria relevante para uma consulta.

Uma pesquisa de 2024 com [Engenheiros de IA](#) identificou que estratégias inadequadas de limpeza e divisão de dados foram a principal causa de falhas em pipelines de RAG em 42% dos casos malsucedidos.

5.2 Chunking Semântico e por Estrutura

A abordagem moderna é respeitar a estrutura semântica do documento. Ferramentas como Unstructured.io implementam chunking por elemento ("title-to-title"), onde cada chunk começa em um título e termina antes do próximo, preservando a coerência temática. Essa estratégia demonstra desempenho significativamente superior em benchmarks de recuperação de informação.

- Chunking por título: agrupa todo o conteúdo sob um mesmo heading
- Chunking semântico: usa embeddings para identificar quebras naturais de assunto
- Chunking hierárquico: mantém metadados de seção e subseção para contexto
- Chunking multimodal: trata texto, tabelas e imagens como elementos independentes

7. O Ecossistema de Ferramentas

O cenário de ferramentas para processamento de PDFs em pipelines de RAG evoluiu consideravelmente. As principais opções podem ser organizadas em categorias:

7.1 Parsers Baseados em Layout e IA

Docling (IBM Research): Utiliza modelos especializados de IA para análise de layout e reconhecimento de estrutura de tabelas. Integra-se nativamente com LangChain, LlamaIndex e Haystack. É open-source e suporta OCR para documentos escaneados.

LlamaParse (LlamaIndex): Parser cloud-based que utiliza modelos de linguagem visual para extrair conteúdo de PDFs complexos, com suporte especial para tabelas, fórmulas matemáticas

e elementos multi-coluna. Benchmarks independentes apontam para performance superior em documentos financeiros.

Unstructured.io: Plataforma focada em pré-processamento de dados não estruturados, com pipelines que combinam visão computacional e PLN para categorização e extração de elementos. O chunking por elemento (title-to-title) demonstrou melhorias significativas em benchmarks de RAG.

MinerU: Solução open-source que retém a estrutura original do documento, incluindo títulos e tabelas, com suporte a OCR para PDFs corrompidos ou escaneados.

7.2 Abordagem Multimodal: Páginas como Imagens

Uma tendência emergente e promissora é abandonar completamente o parsing textual e tratar cada página do PDF como uma imagem, passando-a diretamente para um Vision Language Model (VLM). Ferramentas como Zerox OCR e Morpik adotam essa abordagem.

A vantagem é clara: o VLM “vê” o documento exatamente como um humano o veria, preservando layout, tabelas, gráficos e a ordem de leitura naturalmente. O risco, no entanto, é que modelos de visão podem alucinar ou omitir informações silenciosamente, erros difíceis de detectar em produção.

A abordagem híbrida multimodal (que combina métodos heurísticos de parsing com VLMs como mecanismo de fallback) representa o estado da arte, combinando a confiabilidade do parsing tradicional com a compreensão contextual dos modelos de visão.

8. Boas Práticas Para Pipelines de RAG com PDFs

Com base nos desafios identificados e nas soluções disponíveis, aqui estão as principais recomendações práticas para construir pipelines de RAG robustos com documentos PDF:

Avalie seus documentos antes de escolher a ferramenta: Não existe solução universal. Documentos acadêmicos, relatórios financeiros e manuais técnicos têm características muito diferentes. Analise uma amostra representativa do seu corpus antes de definir a estratégia de parsing.

Trate texto, tabelas e imagens como modalidades separadas: Em vez de tentar converter tudo para texto puro, considere pipelines que extraem cada tipo de elemento separadamente, aplicam o tratamento adequado para cada modalidade e armazenam com metadados que indicam o tipo de conteúdo.

Invista em pré-processamento de OCR: Para documentos escaneados, o pré-processamento da imagem (deskewing, redução de ruído, aumento de contraste) antes do OCR pode melhorar significativamente a qualidade da extração. Erros de OCR se propagam por todo o pipeline.

Use chunking semântico, não chunking por tokens: Prefira estratégias que respeitem as fronteiras naturais do documento (seções, parágrafos, elementos de tabela) em vez de divisões arbitrárias por contagem de tokens. Preserve metadados de contexto (título da seção, número de página) em cada chunk.

Implemente avaliação contínua da qualidade: Monitore a qualidade do parsing em produção. Um documento que funciona bem hoje pode ser seguido de um com layout diferente que quebre o pipeline. Métricas de qualidade de recuperação (como nDCG e ROUGE) devem ser monitoradas continuamente.

Considere permissões e privacidade: Em implementações corporativas, todo o conteúdo dos PDFs é ingerido em um banco de vetores centralizado. É essencial implementar controles de acesso no nível do chunk para garantir que documentos restritos não “vazem” para usuários sem autorização através das respostas do LLM.

Conclusão

O PDF é, paradoxalmente, o formato mais universal de documentos corporativos e também um dos mais desafiadores para sistemas de IA. Sua filosofia de design (otimizado para apresentação visual humana, não para processamento semântico por máquinas) cria obstáculos reais que impactam diretamente a qualidade das respostas em sistemas de RAG.

A boa notícia é que o ecossistema de ferramentas evoluiu significativamente. Soluções como Docling, LlamaParse e abordagens híbridas multimodais oferecem caminhos concretos para superar esses desafios. O segredo está em entender profundamente a natureza dos seus documentos, escolher as ferramentas certas para cada caso e implementar avaliação contínua da qualidade do pipeline.

Em última análise, a premissa “garbage in, garbage out” nunca foi tão relevante quanto em sistemas de RAG: a qualidade do parsing do PDF é o alicerce sobre o qual toda a precisão do sistema é construída. Vale o investimento em fazer isso bem feito.

E se quiser desenvolver suas habilidades na construção de sistemas e pipelines de RAG de forma profissional, temos uma Formação completa para ajudar você: